

Árboles de Decisión

Una prestigiosa institución de educación superior confeccionó una base de datos con el fin de predecir la deserción o el éxito académico de los estudiantes. El conjunto de datos incluye información conocida en el momento de la inscripción del estudiante (trayectoria académica, datos demográficos y factores socioeconómicos) y el rendimiento académico de los estudiantes al final del primer y segundo semestre.

(a) *Exploración de datos:*

1. Cargar la base de datos utilizando `fetch_ucirepo` (ucimlrepo), proveniente de <https://archive.ics.uci.edu/dataset/697>.
2. Modificar la variable *target*, para clasificar si se graduará al finalizar el curso (clasificación binaria).
3. Catalogar cada predictor (*feature*) en ordinales y nominales. Codificar las variables nominales como *One-Hot*.
4. Utilice el comando `train_test_split` (sklearn) para definir dos conjuntos con las proporciones 75% y 25%.

(b) *Árbol de decisión:*

1. Utilizando el comando `tree.DecisionTreeClassifier` (sklearn), entrenar un árbol de clasificación maximal con entropía como función de impureza. Mencionar la condición de la raíz y los primeros nodos.
2. Utilizando `plot_tree` (sklearn) graficar el diagrama de árbol. Indicar la cantidad de nodos y hojas.
3. Indicar el *accuracy* y la F1, evaluados con los datos de testeo.
4. Indicar los 2 *features* más relevantes según la *Feature Importance*.

(c) *Podado:*

1. Utilizando `cost_complexity_pruning_path` (sklearn), calcular todos los α relevantes para la poda de un árbol de decisión.
2. Repetir la implementación del inciso (b) para un árbol podado para una complejidad α .
3. Graficar la cantidad de hojas en función de α .
4. Graficar el *accuracy* (evaluado con los datos de testeo) en función de α .
5. Graficar la F1 (evaluado con los datos de testeo) en función de α .
6. Indicar los 2 *features* más relevantes según la *Feature Importance* para el árbol de mejor F1 de testeo.

(d) *Bosque Aleatorio:*

1. Utilizando el comando `RandomForestClassifier` (sklearn), entrenar un clasificador de 20 árboles.
2. Indicar el *accuracy* y la F1, evaluados con los datos de testeo.
3. Indicar los 2 *features* más relevantes según la *Feature Importance*.